

ESTRUTURAS DE DADOS E ALGORITMOS II · EDA II

Análise de Utilidade em Reviews de E-commerce

via Grafos de Coocorrência de Palavras



Pipeline em Python

NLP · Tokenização


Teoria dos Grafos

Relatório HTML

Projeto desenvolvido para a disciplina de Estruturas de Dados e Algoritmos II

Autores · Equipe EDA II

Um pipeline que lê reviews e devolve estrutura



O software processa textos de avaliações, constrói grafos de palavras e gera um relatório analítico consolidado — tudo a partir de um menu interativo no terminal.



Execução via CLI

Menu interativo no terminal controla todo o pipeline passo a passo.



Relatório dinâmico em HTML

Saída final consolida métricas e gráficos numa única interface navegável.

3 CATEGORIAS DE SATISFAÇÃO



BAD reviews

Avaliações de baixa satisfação




MID reviews

Avaliações intermediárias



GOOD reviews

Avaliações de alta satisfação




O que torna uma avaliação realmente útil?

Pergunta de pesquisa: quais características de um review aumentam sua utilidade percebida por outros consumidores — medida pelos votos em “Esta avaliação foi útil?”




Reviews ÚTEIS

- Descrições detalhadas sobre características do produto.
- Redes semânticas densas e especializadas.
- Termos técnicos e descritivos.



Reviews POUCO ÚTEIS

- Opiniões genéricas e expressões emocionais.
- Estruturas esparsas e menos informativas.
- Vocabulário difuso, sem especialização.



Pipeline em cinco etapas

01

Extração

Leitura e seleção dos dados relevantes do dataset de reviews.

02

Pré-processamento

NLP: minúsculas, remoção de pontuação e stopwords, tokenização.

03

Construção do Grafo

Palavras viram nós; coocorrências viram arestas ponderadas.

04

Análise de Redes


Métricas topológicas, PageRank e detecção de comunidades.

05

Comparação

Grafos independentes por categoria, comparados estruturalmente.

Cada etapa exporta artefatos intermediários (CSV, JSON, grafos) — o pipeline é reproduzível e auditável de ponta a ponta.



Do texto bruto ao grafo de coocorrência

PRÉ-PROCESSAMENTO (NLP)

- Conversão para minúsculas
- Remoção de pontuação
- Remoção de stopwords
- Tokenização das avaliações

REGRAS DE CONSTRUÇÃO DO GRAFO



Nós Cada palavra única é um nó do grafo.




Arestas Ligam palavras que coocorrem numa janela deslizante de texto.




Peso Número de coocorrências observadas entre o par.

Grafo não-direcionado · NetworkX



Nós maiores = hubs vocabulares (maior centralidade)



Medindo a forma e o centro do discurso


MACROANÁLISE · a forma global da rede




MICROANÁLISE · o centro da rede

-  **PageRank** define a centralidade e revela os hubs vocabulares — as palavras que ancoram o discurso.
-  **Acoplamento forte** extrai as arestas de maior peso — combos semânticos rígidos do vocabulário.

Top palavras por PageRank — exemplo ilustrativo





Comparando o discurso: GOOD × BAD




Hubs Globais

Interseção de conjuntos identifica as palavras comuns a todas as categorias — o núcleo compartilhado do discurso.



Assinaturas Exclusivas


Termos que aparecem em apenas uma categoria revelam o vocabulário característico de cada nível de satisfação.



Deslocamento de Centralidade

Palavras que mudam drasticamente de ranking do GOOD para o BAD — sinais de virada no tom do discurso.

Técnica central: operações de conjuntos sobre os rankings de PageRank de cada grafo categórico.



O relatório HTML em cinco lentes



Distribuição de Grau

Histograma long-tail × hubs.



Top 10 PageRank

Barras comparando centralidade.



Heatmap de Coocorrência

Matriz de calor dos nós fortes.



Scatter de Deslocamento

Dispersão GOOD × BAD.




Word Clouds

Nuvens ponderadas por PageRank, não por frequência pura.



Relatório Integrado

Tudo reunido numa interface HTML navegável.



Subestruturas avançadas de redes



Algoritmo de Louvain

Detecção automática de comunidades — isola bolhas temáticas no discurso, agrupando palavras que conversam entre si.



K-Core Decomposition


Remove nós periféricos para expor o “núcleo duro”: a espinha dorsal inquebrável das reviews.



Diagrama de Sankey

Fluxo semântico (ego-network): ramificações de contexto a partir de uma palavra-chave central.

Diferenciais que vão além do escopo básico — teoria dos grafos aplicada à semântica do texto.



As ferramentas por trás do pipeline



Linguagem & Dados

- Python 3.13+
- Pandas · NumPy



Grafos

- NetworkX
- Louvain · K-Core



NLP

- NLTK · SpaCy
- Tokenização · stopwords



Visualização

- Matplotlib · Seaborn
- Word Clouds · Heatmaps



Saídas

- JSON · Markdown · HTML
- Relatório consolidado



Gestão


- Poetry (dependências)
- Ambiente reproduzível

O que a estrutura revela



Palavras mais influentes

Hubs de PageRank identificam os termos que sustentam reviews úteis.



Comunidades temáticas

Louvain agrupa aspectos do produto em bolhas de discurso.



Comparação estrutural

Diferenças mensuráveis de densidade e centralidade entre útil × não-útil.



Hipótese: reviews úteis formam redes semânticas mais densas e especializadas; reviews pouco úteis, estruturas genéricas e emocionais.

